

Módulo 6  
Clase 2-2

# Aprendizaje de Máquina No Supervisado

# Objetivos

- Utiliza los conceptos básicos de aprendizaje de máquinas no supervisado.
- Conocer los distintos tipos de algoritmos.
- Diferenciar entre supervisado y no supervisado.
- Casos de uso.





# Contenido



- Demostración Clusterización
- Demostración Reducción Dimensionalidad
- Demostración Detección Anomalías

# Consejos para el éxito!

- Practicar lo más que puedan (recomendación: media hora por día)
- No sentirse frustrado o con miedo (es parte de aprender tener errores al inicio)
- Ser parte de una comunidad, compartir errores y soluciones




“Tu FUTURO se decide por  
lo que haces HOY, no  
MAÑANA”

# Demostración

# Clusterización

**Clustering**, también conocido como agrupamiento, es una técnica de aprendizaje no supervisado en la que se utilizan algoritmos para identificar grupos o clústeres de objetos o datos similares. El objetivo principal del clustering es agrupar objetos similares juntos y separar objetos diferentes en grupos distintos, sin tener una clasificación previa de los datos.

El algoritmo de clustering, funciona al analizar las características de los datos, buscando patrones y similitudes en los valores. Estos patrones se utilizan para agrupar los objetos o datos en clusters o grupos.



Corresponde a técnicas de Machine Learning no-supervisado en donde a partir de datos no etiquetados, se le asigna una etiqueta.




# Reducción de dimensionalidad

- La reducción de dimensionalidad se utiliza para abordar varios problemas en el análisis de datos, incluyendo la complejidad computacional, la visualización de datos y la mejora del rendimiento de los modelos de aprendizaje automático.

Al reducir la cantidad de variables, es posible **disminuir la complejidad computacional de ciertas tareas**, como la clasificación y la agrupación de datos. Además, la reducción de dimensionalidad puede **ayudar a visualizar datos en espacios de menor dimensión**, lo que puede ayudar a comprender mejor las relaciones entre las variables. Finalmente, la reducción de dimensionalidad puede mejorar el rendimiento de los modelos de aprendizaje automático, al **reducir el ruido en los datos y mejorar la generalización**.

Menor  
complejidad

Simplicidad



Mejor  
generalización

Mejor  
visualización

# Caso Wines

El siguiente dataset, corresponde a mediciones de propiedades químicas de vinos procedentes de 3 cultivos distintos de un área específica de Italia. El dataset, contiene los resultados de 178 mediciones de 13 variables químicas medidas para cada muestra. A continuación, una muestra:

Alcohol	Malic Acid	Ash	Alcalinity of ash	Magnesium	Total phenols	Flavanoids	Nonflavanoid phenols	Proanthocyanins	Color intensity	Hue	D280/OD315 of diluted wines	Proline
14.23	1.71	2.43	15.6	127	2.80	3.06	0.28	2.29	5.64	1.040	3.92	1065
13.20	1.78	2.14	11.2	100	2.65	2.76	0.26	1.28	4.38	1.050	3.40	1050
13.16	2.36	2.67	18.6	101	2.80	3.24	0.30	2.81	5.68	1.030	3.17	1185
14.37	1.95	2.50	16.8	113	3.85	3.49	0.24	2.18	7.8	0.860	3.45	1480
13.24	2.59	2.87	21.0	118	2.80	2.69	0.39	1.82	4.32	1.040	2.93	735
14.20	1.76	2.45	15.2	112	3.27	3.39	0.34	1.97	6.75	1.050	2.85	1450

## Alcohol

Alcohol

## Malic

Malic acid

## Ash

Ash

## Alcalinity

Alcalinity of ash

## Magnesium

Magnesium

## Phenols

Total phenols

## Flavanoids

Flavanoids

## Nonflavanoids

Nonflavanoid phenols

## Proanthocyanins

Proanthocyanins

## Color

Color intensity.

## Hue

Hue

## Dilution

D280/OD315 of diluted wines.

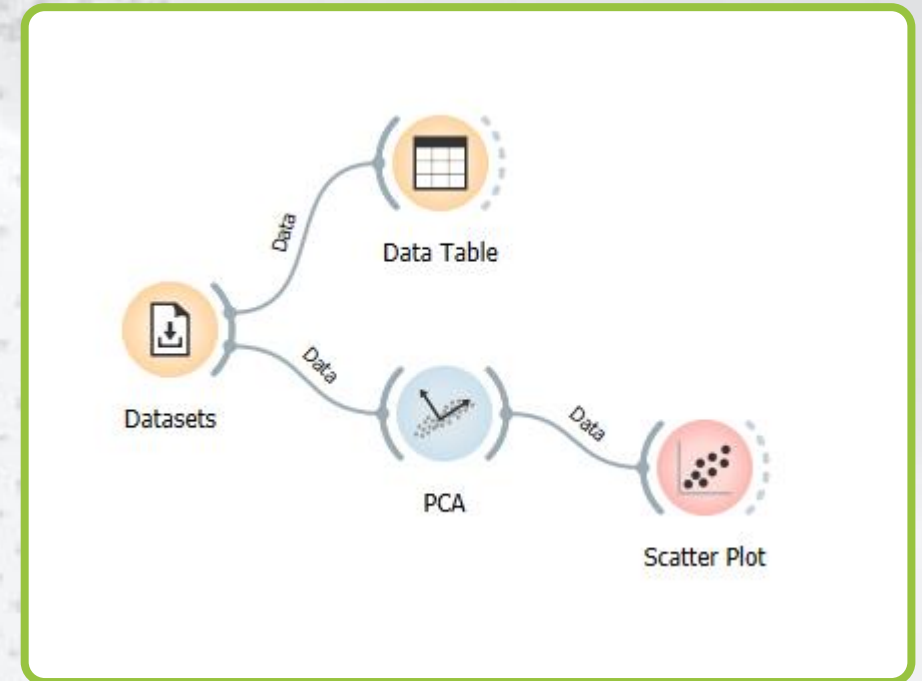
## Proline

Proline



# Caso Wines


- Bajo el supuesto que cada cultivo tuvo un tratamiento homogéneo pero característico, es posible pensar que cada cultivo tenga mediciones similares. De esta forma, se podría agrupar dichos datos y determinar la cantidad de cultivos y a qué cultivo pertenece cada medición.
- El principal problema, es que 13 features son difíciles de explorar. Es por esto, que primero **realizaremos una tarea de Reducción de Dimensionalidad de los datos**. La idea es disminuir la dimensionalidad tratando de perder la menor información manteniendo la esencia de los datos. Perderemos algo de exactitud, pero ganaremos en visualización. Lo anterior, es muy simple de realizar en Orange.



## Caso Wines

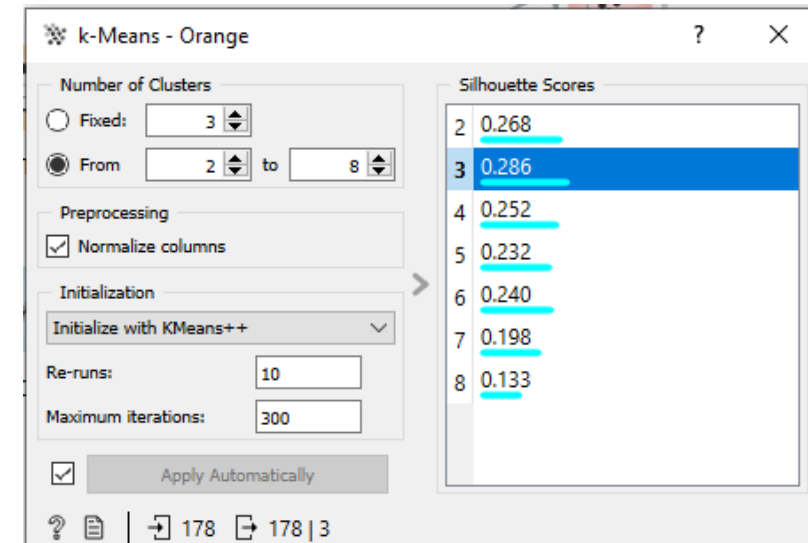



El siguiente diagrama, nos muestra nuestro set de datos original de 13 dimensiones, proyectado en un espacio de sólo 2 dimensiones (componentes principales). Nótese que se aprecian grupos de datos similares, es decir, datos próximos unos de otros.



# Caso Wines


Ahora ejecutaremos una tarea de clusterización, para que el algoritmo pueda encontrar cuáles son los grupos o clusters con instancias consideradas similares. Para esto, incorporaremos un algoritmo clusterizador llamado K-Means, dejaremos que haga su trabajo y veremos el resultado.






# Caso Wines

Ahora visualizaremos los clusters encontrados por K-Means. Nótese que fueron identificados 3 clusters, por lo tanto, podríamos pensar que los datos corresponden a 3 cultivos distintos. Cada cultivo estaría representado en un cluster identificado con un color distintivo.




# Caso Wines

Pues bien, en aprendizaje no supervisado, no podemos comparar contra las etiquetas reales puesto que éstas no son conocidas. Sin embargo, en el dataset utilizado sí se poseían las etiquetas de cada cultivo, por lo tanto, vamos a comparar qué tan certero fue el procedimiento no supervisado con la realidad. Como se aprecia, hay una gran similitud entre los clusters encontrados de forma no supervisada y los valores reales.




Cultivos reales



Clusters encontrados

# Caso Titanic

Ahora haremos un poco de aprendizaje no supervisado sobre el dataset del Titanic. Para eso, vamos a leer el archivo de Titanic que hemos trabajado en los módulos anteriores. Realizaremos algunas imputaciones en las columnas de Age y Embarked con el imputador algorítmico.



Impute - Orange

Default Method

- ☐ Don't impute
- ☐ Average/Most frequent
- ☐ As a distinct value
- ☐ Fixed values; numeric variables: 0, time: 1969-12-31 21:00:00
- ☒ Model-based imputer (simple tree)
- ☐ Random values
- ☐ Remove instances with unknown values

Individual Attribute Settings

Filter...	
<input checked="" type="checkbox"/> PassengerId -> leave	<input type="radio"/> Default (above)
<input checked="" type="checkbox"/> Survived -> leave	<input type="radio"/> Don't impute
<input checked="" type="checkbox"/> Pclass -> leave	<input type="radio"/> Average/Most frequent
<input checked="" type="checkbox"/> Sex -> leave	<input type="radio"/> As a distinct value
<input checked="" type="checkbox"/> Age -> model (simple tree)	<input checked="" type="radio"/> Model-based imputer (simple tree)
<input checked="" type="checkbox"/> SibSp -> leave	<input type="radio"/> Random values
<input checked="" type="checkbox"/> Parch -> leave	<input type="radio"/> Remove instances with unknown values
<input checked="" type="checkbox"/> Fare -> leave	<input type="radio"/> Fixed value
<input checked="" type="checkbox"/> Embarked -> model (simple tree)	C

Restore All to Default

☒ Apply Automatically

? | 891 | - | 891



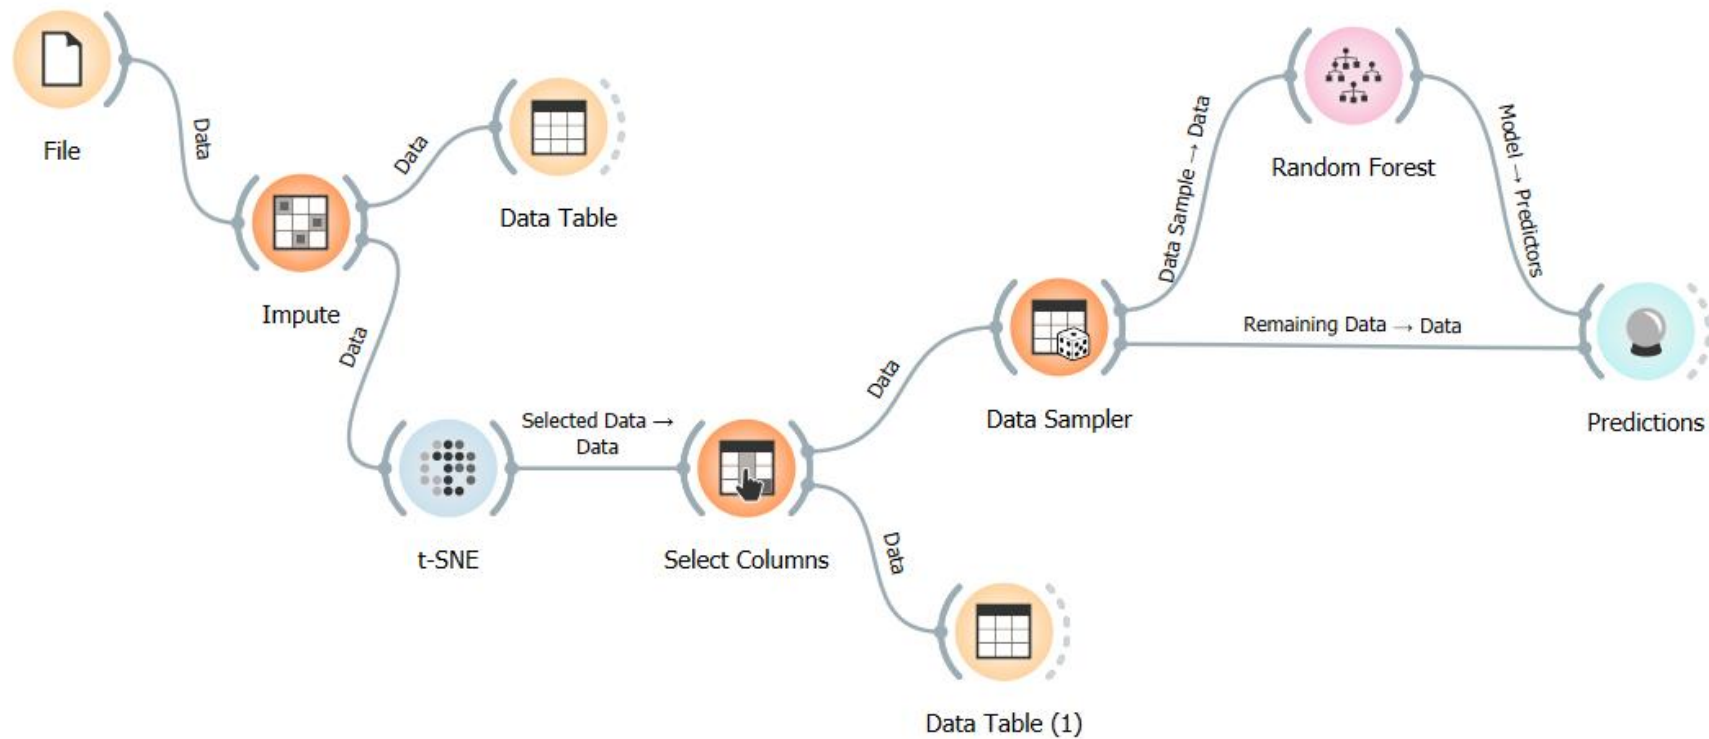
# Caso Titanic

Realizaremos un proceso de disminución de dimensionalidad con el algoritmo t-SNE y visualizaremos los datos en un espacio de dos dimensiones. En esta caso, al hacer la proyección a dos dimensiones, se puede ver que ahora es más fácil diferenciar a los sobrevivientes de los no sobrevivientes.



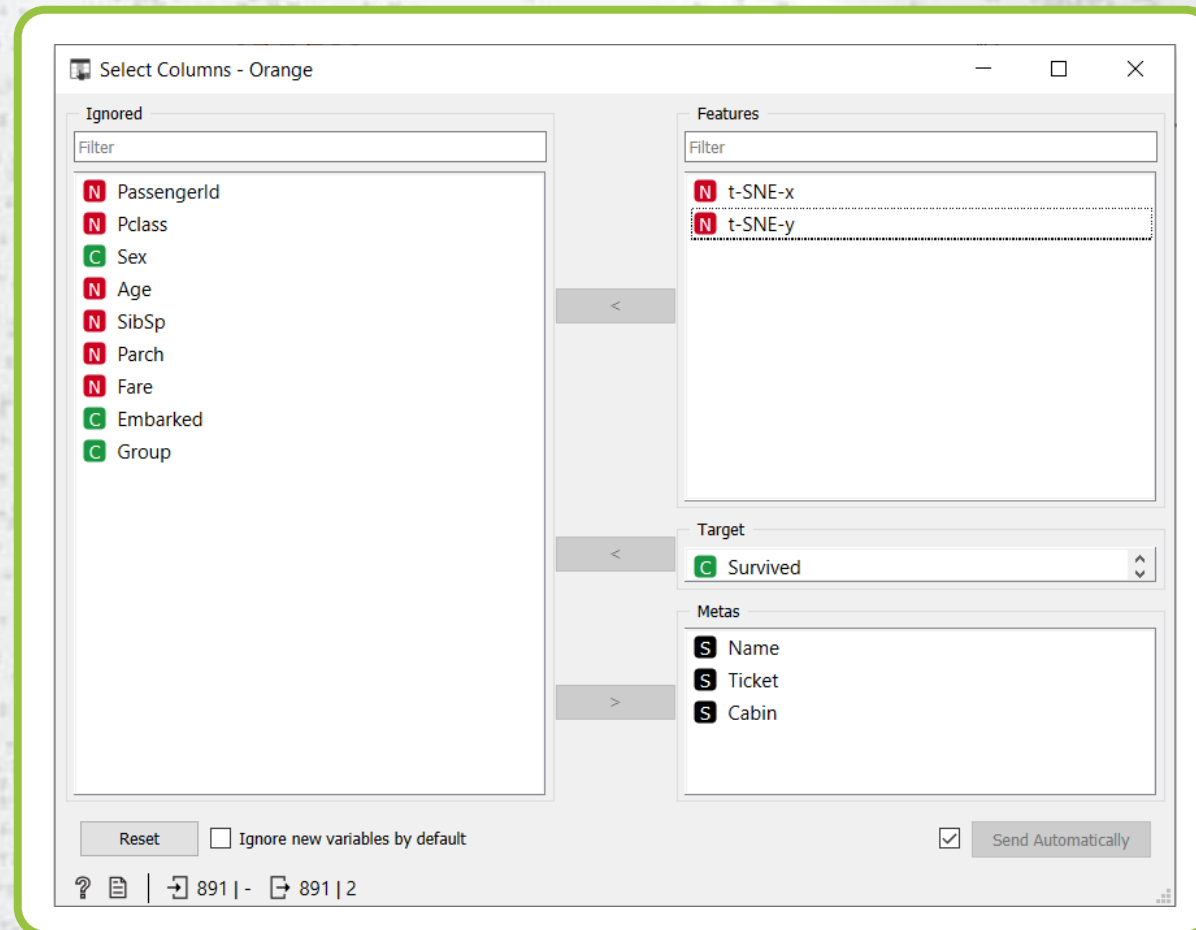
# Caso Titanic

Lo que haremos ahora, será aplicar una tarea de clasificación con un algoritmo de aprendizaje supervisado de acuerdo al siguiente flujo.



# Caso Titanic

Nótese que agregamos un paso de selección de columnas en donde hemos dejado para el modelo supervisado los valores en el nuevo espacio de dos dimensiones reducido por t-SNE. La variable objetivo sigue siendo Survived.





# Caso Titanic

Estos son los resultados obtenidos luego de incorporar la tarea no supervisada de reducción de dimensionalidad.  
Accuracy=99,3%

Predictions - Orange

Show probabilities for: Classes in data Restore Original Order

	Random Forest	Survived	Name	Ticket	Cabin	t-SNE-x	t-SNE-y
1	1.00 : 0.00 → 0	0	Taussig, Mr. Emil	110413	E67	-13.0251	-10.7555
2	1.00 : 0.00 → 0	0	Andersson, Mrs...	347082	?	6.64736	5.52732
3	0.00 : 1.00 → 1	0	Allison, Miss. H...	113781	C22 C26	15.5689	0.441987
4	0.25 : 0.75 → 1	1	Sundman, Mr. J...	STON/O 2. 310...	?	-1.34421	-21.5365
5	1.00 : 0.00 → 0	0	Bateman, Rev. R...	S.O.P. 1166	?	-15.5944	-6.7635
6	1.00 : 0.00 → 0	0	Morley, Mr. He...	250655	?	-24.5649	-7.5068
7	1.00 : 0.00 → 0	0	Guggenheim, ...	PC 17593	B82 B84	11.7678	-26.3745
8	0.00 : 1.00 → 1	1	Thayer, Mr. Joh...	17421	C70	15.02	-17.7792
9	1.00 : 0.00 → 0	0	Somerton, Mr. ...	A.5. 18509	?	-21.1737	5.10572
10	1.00 : 0.00 → 0	0	Ford, Miss. Robi...	W./C. 6608	?	2.32149	10.8756
11	0.00 : 1.00 → 1	1	Andersson, Mr. ...	350043	?	0.653264	-20.9332
12	1.00 : 0.00 → 0	0	Pasic, Mr. Jakob	315097	?	-29.7351	3.10679
13	1.00 : 0.00 → 0	0	Ham, Mr. Len	1601	?	-28.4668	-5.16282

☒ Show performance scores Target class: (Average over classes)

Model	AUC	CA	F1	Precision	Recall
Random Forest	0.993	0.993	0.993	0.993	0.993

267 | 267 | 1x267

Predicted

	0	1	Σ
0	167	2	169
1	0	98	98
Σ	167	100	267


Actual

La detección de anomalías es un proceso de identificación de patrones inusuales o atípicos en datos, que difieren significativamente de la mayoría de los demás datos en un conjunto. Las anomalías también se conocen como "outliers" o valores atípicos.

La detección de anomalías es un campo importante en la minería de datos y el aprendizaje automático, y se utiliza en diversas aplicaciones, como la detección de fraudes en transacciones financieras, el monitoreo de sistemas informáticos para detectar intrusiones, la detección de fallas en equipos industriales y la vigilancia de la salud en pacientes para identificar patologías.


Los métodos de detección de anomalías pueden ser supervisados o no supervisados. En el enfoque no supervisado, se busca identificar patrones inusuales sin la ayuda de etiquetas de clase previas. En el enfoque supervisado, se entrena un modelo con ejemplos etiquetados de datos normales y luego, se utilizan estos modelos para identificar datos anómalos.

## Detección de Anomalías



# Detección de anomalías

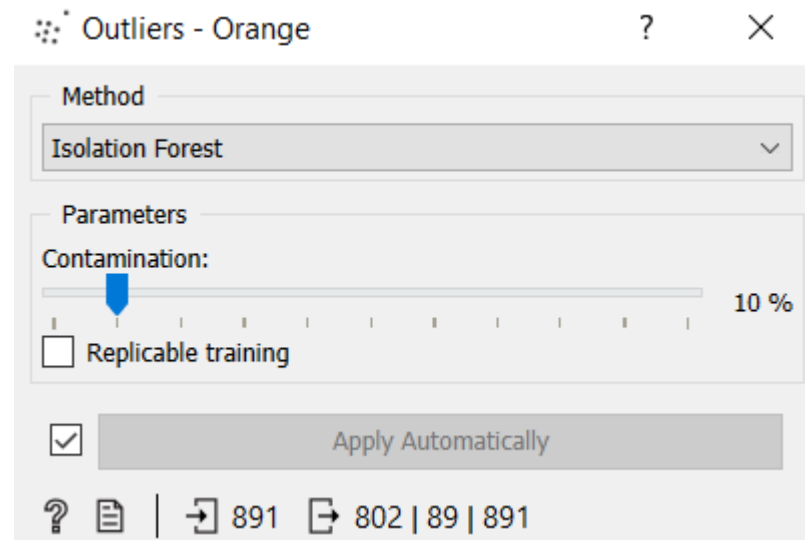
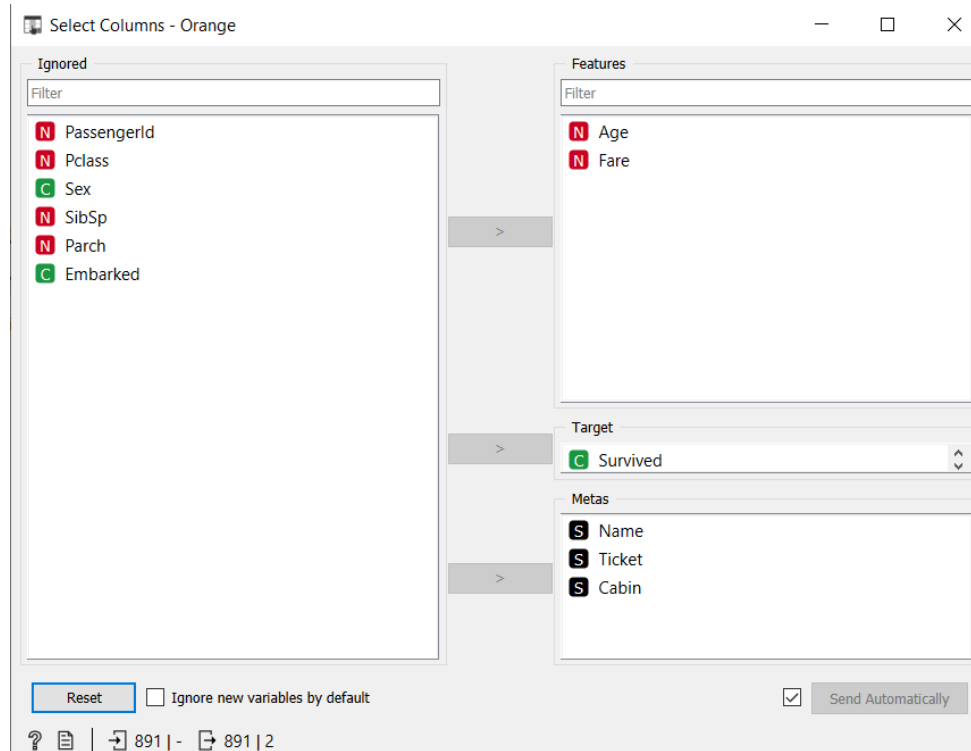
Ahora, analizaremos el dataset Titanic para detectar outliers en los datos. A continuación, se presenta el flujo en donde se ha realizado una tarea de detección de outliers.






# Detección de Anomalías

Para este ejemplo, hemos seleccionado sólo las columnas Age y Fare. Y se ha utilizado el algoritmo Isolation Forest para la detección de anomalías.




# Detección de anomalías

Acá se puede apreciar los puntos que son considerados inliers y los que son considerados outliers de acuerdo al algoritmo.



Inliers



Outliers

The background of the slide is a grayscale image of a book cover. The cover features a repeating pattern of stylized, overlapping leaf or feather shapes. A solid green horizontal banner is positioned across the middle of the image, containing the text 'Dudas y consultas' in white.

Dudas y consultas

Gracias