


Módulo 7
Clase 2

Introducción a las Redes Neuronales

Especialización en Ciencia de Datos 2023

Objetivos

- Describir los conceptos fundamentales las redes neuronales y su utilidad para la resolución de problemas de aprendizaje de máquina



Contenido



- ④ Un poco de Historia
- ④ Qué es una red neuronal
- ④ El Perceptrón
- ④ Implementando un perceptrón

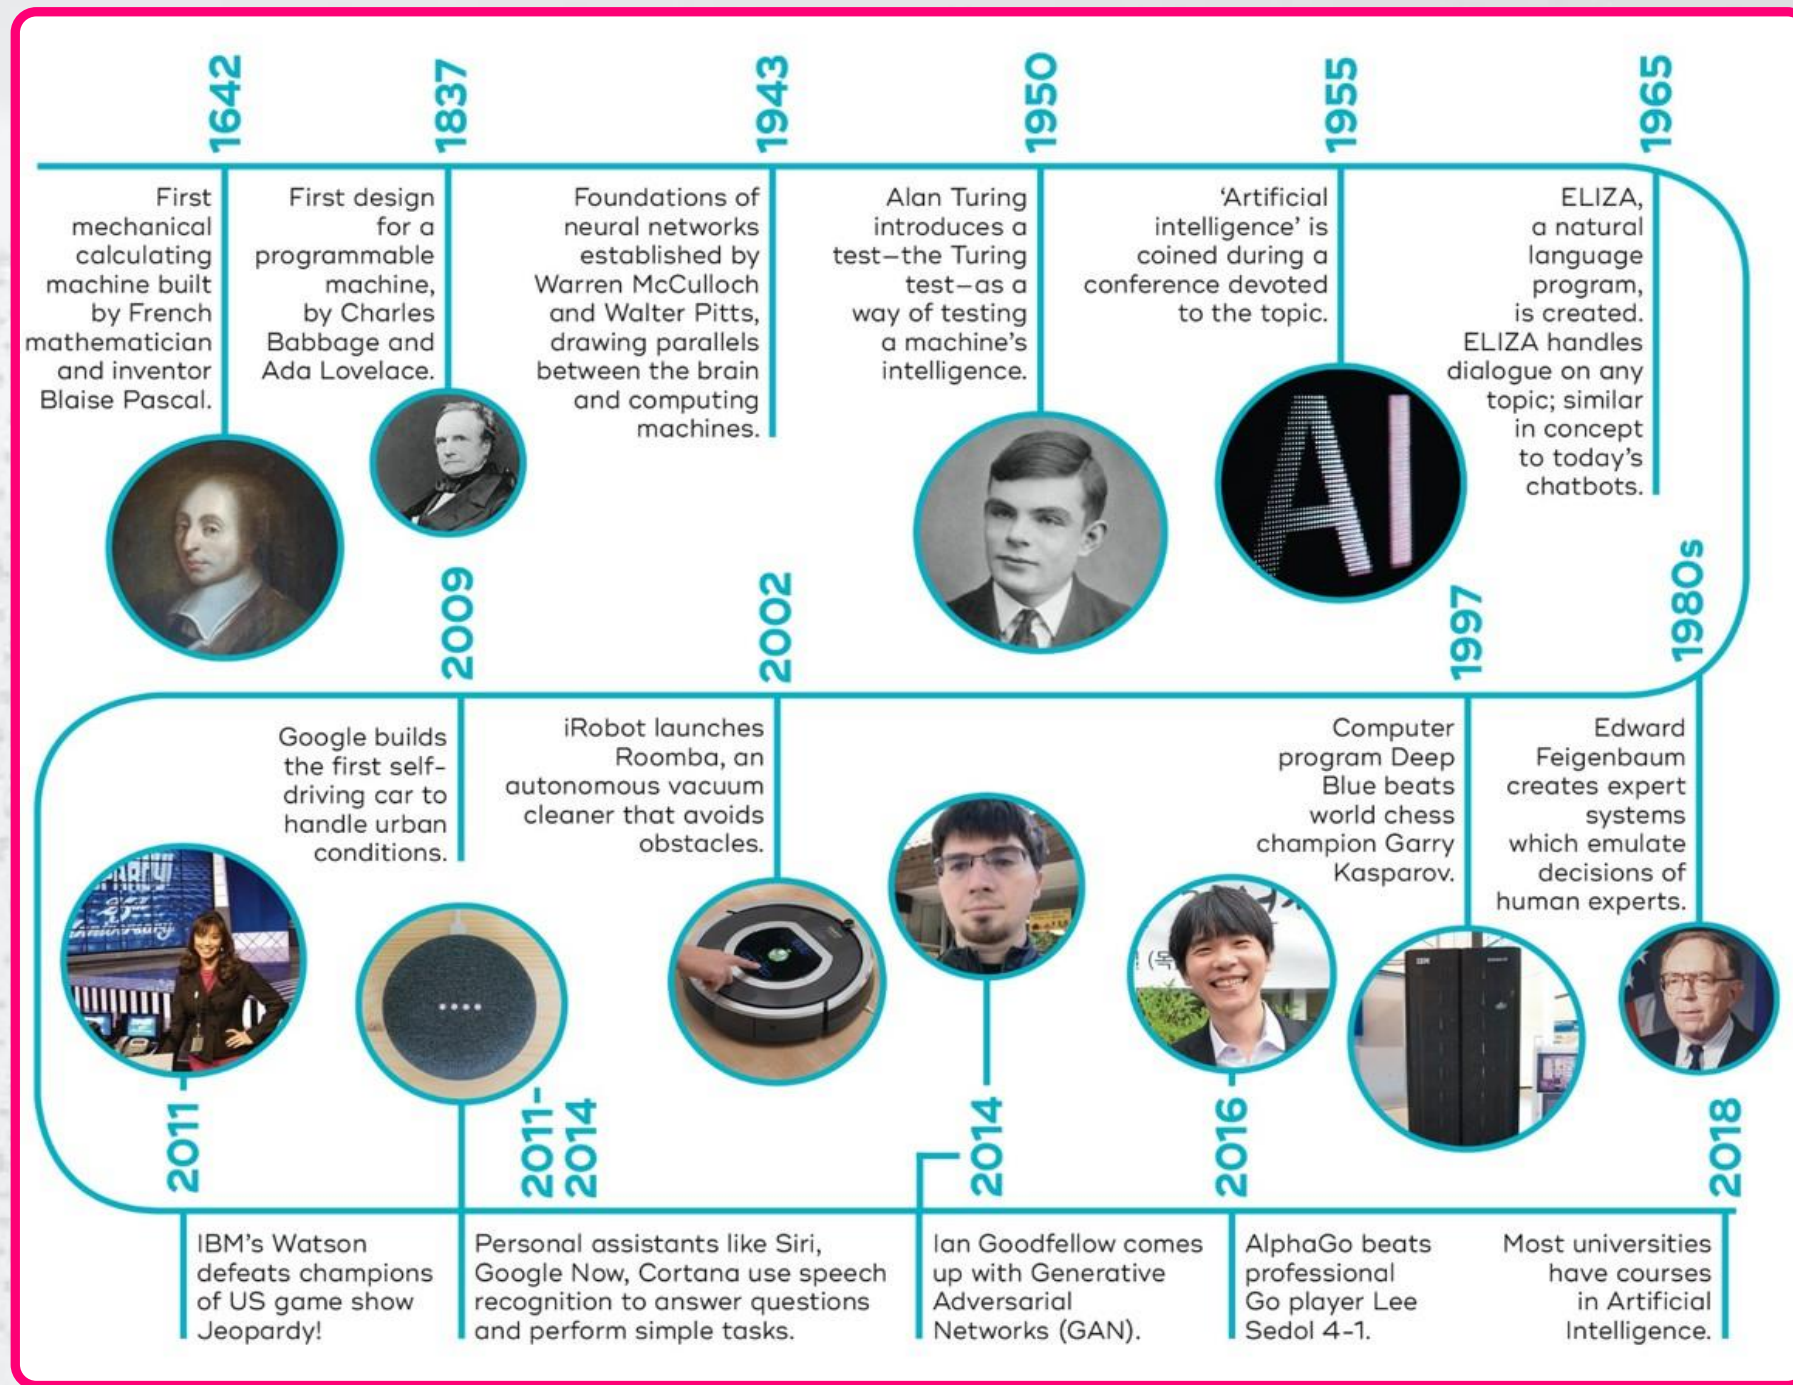
Un poco de historia

Un poco de Historia

Historia de la IA: Frank Rosenblatt y el Mark I Perceptrón, el primer ordenador fabricado específicamente para crear redes neuronales en 1957




Un poco de Historia



Qué es una Red Neuronal

¿Qué es una Red Neuronal?



Es un paradigma de programación hermosamente inspirado en la biología que permite a las máquinas aprender a partir de datos observados. Redes Neuronales y Deep Learning ofrecen las mejores soluciones para el reconocimiento de imágenes, procesamiento del lenguaje natural, reconocimiento de voz, entre otros.



Conexiones Neuronales

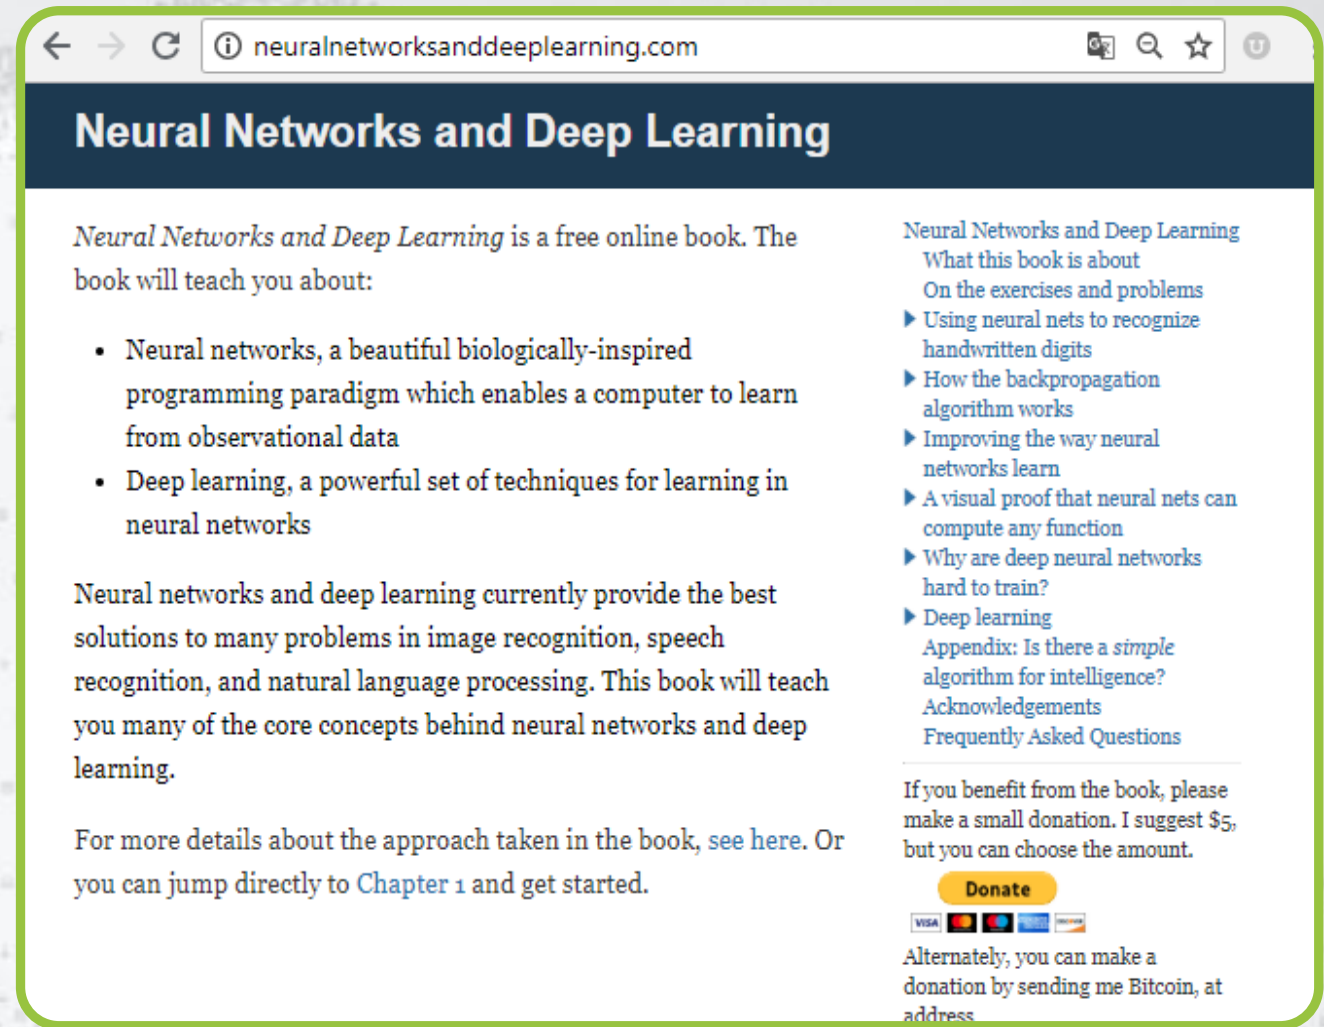
Las comunicaciones neuronales dependen de señales eléctricas y químicas. Una neurona genera una señal eléctrica que es conducida por el Axon.

Las Dendritas reciben las señales eléctricas, y basados en estas señales de entrada, las conducen a otras neuronas.



Bibliografía Recomendada

Recomendamos esta web en donde puedes bajar un libro gratis de Deep learning.



The screenshot shows a web browser window with the address bar displaying "neuralnetworksanddeeplearning.com". The page title is "Neural Networks and Deep Learning". The main content area describes the book as a free online resource and lists topics it covers, including neural networks and deep learning techniques. A sidebar on the right provides a table of contents with links to various sections. At the bottom, there is a "Donate" button and information about alternative donation methods like Bitcoin.

← → ↻ ⓘ neuralnetworksanddeeplearning.com

Neural Networks and Deep Learning

Neural Networks and Deep Learning is a free online book. The book will teach you about:

- Neural networks, a beautiful biologically-inspired programming paradigm which enables a computer to learn from observational data
- Deep learning, a powerful set of techniques for learning in neural networks

Neural networks and deep learning currently provide the best solutions to many problems in image recognition, speech recognition, and natural language processing. This book will teach you many of the core concepts behind neural networks and deep learning.

For more details about the approach taken in the book, [see here](#). Or you can jump directly to [Chapter 1](#) and get started.

Neural Networks and Deep Learning

- What this book is about
- On the exercises and problems
- ▶ Using neural nets to recognize handwritten digits
- ▶ How the backpropagation algorithm works
- ▶ Improving the way neural networks learn
- ▶ A visual proof that neural nets can compute any function
- ▶ Why are deep neural networks hard to train?
- ▶ Deep learning
- Appendix: Is there a *simple* algorithm for intelligence?
- Acknowledgements
- Frequently Asked Questions

If you benefit from the book, please make a small donation. I suggest \$5, but you can choose the amount.

[Donate](#)

VISA MASTERCARD AMERICAN EXPRESS


Alternately, you can make a donation by sending me Bitcoin, at address

<http://neuralnetworksanddeeplearning.com>

El Perceptrón

El Perceptrón

El Perceptrón es una metáfora de una neurona, de tipo artificial, desarrollado en 1950 por el científico Frank Rosenblatt. Un perceptrón toma varias entradas (x_1, \dots, x_n) y devuelve una sola salida, mediante un procesamiento.



Ejemplo de un Perceptrón


► Modelaremos un perceptrón para representar la siguiente situación. Suponga que:

x_1 : es la variable que indica si es día de semana o fin de semana (0 día de semana, 1 fin de semana).

x_2 : es la variable que indica si tu novia te visitará (0 no te visitará, 1 sí te visitará).


x_3 : es la variable que indica si hay buen tiempo o mal tiempo (0 mal tiempo, 1 buen tiempo).

Output: es la respuesta acerca si irás al festival de Jazz de la ciudad. (0 no vas, 1 si vas)



Asignando Pesos

Cada factor o variable tendrá un mayor o menor peso en la decisión que tomarás. Para esto, introduciremos en el modelo los valores de w_1 , w_2 y w_3 que son números reales y expresan la importancia de cada variable en la decisión.



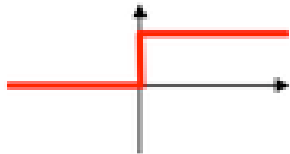
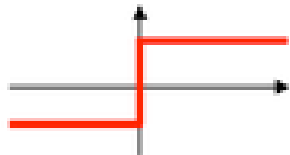
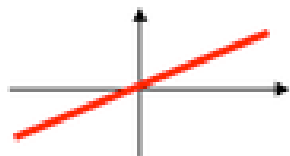
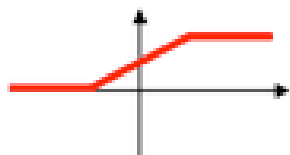
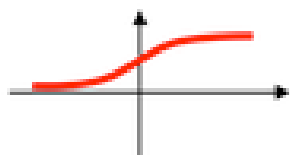
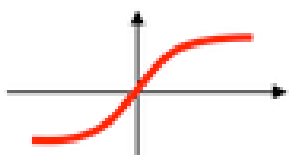
Decisión

La decisión tomada en la salida corresponderá a si la suma de los pesos por valores de las variables es mayor o menor que un umbral. El umbral también es un parámetro numérico.

$$salida = \begin{cases} 0 & , \quad \sum w_j x_j \leq umbral \\ 1 & , \quad \sum w_j x_j > umbral \end{cases}$$

Función de Activación


La función mostrada anteriormente es la más simple, pero en realidad hay varias funciones de activación que se podrían utilizar para generar la salida a partir de las variables y los pesos asignados.

Activation function	Equation	Example	1D Graph
Unit step (Heaviside)	$\phi(z) = \begin{cases} 0, & z < 0, \\ 0.5, & z = 0, \\ 1, & z > 0, \end{cases}$	Perceptron variant	
Sign (Signum)	$\phi(z) = \begin{cases} -1, & z < 0, \\ 0, & z = 0, \\ 1, & z > 0, \end{cases}$	Perceptron variant	
Linear	$\phi(z) = z$	Adaline, linear regression	
Piece-wise linear	$\phi(z) = \begin{cases} 1, & z \geq \frac{1}{2}, \\ z + \frac{1}{2}, & -\frac{1}{2} < z < \frac{1}{2}, \\ 0, & z \leq -\frac{1}{2}, \end{cases}$	Support vector machine	
Logistic (sigmoid)	$\phi(z) = \frac{1}{1 + e^{-z}}$	Logistic regression, Multi-layer NN	
Hyperbolic tangent	$\phi(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	Multi-layer NN	


Función de Activación

Estas son las funciones de activación más comunes:


Tanh




ReLU



Sigmoid




Linear




Función de Activación


Sigmoid




Tanh




Step Function




Softplus




ReLU




Softsign




ELU




Log of Sigmoid



Swish



Sinc



Leaky ReLU




Mish



Función de Activación


Si buscamos que una neurona retorne un valor binario (es decir 0 ó 1), ¿qué tipo de función de activación podemos utilizar?



El Perceptrón

El Perceptrón trabaja de la siguiente forma:

x1	x2	x3
1.5	4.8	2.2
3.4	0.6	1.7
-2.3	7.2	-0.2



1. Recibe un input



2. Se asigna peso a cada input

3. Computa los inputs

4. Genera la respuesta

La Metáfora

Acá podemos observar la analogía entre una neurona y un perceptrón.



A cartoon drawing of a biological neuron (left) and its mathematical model (right).

Playground

<https://aegeorge42.github.io/>



neuron

net

backpropagation


calculus

SANDBOX

Here's a neuron.

A neuron takes in some inputs...

(each input is a single number)



back

next

Implementación de un Perceptrón

Implementando un perceptrón

Imagina que contamos con datos del comportamiento de una persona respecto a sus decisiones de ir a jugar tenis el sábado por la mañana.

Voy a jugar tenis si no está lloviendo, no hace mucho calor, ni tanto frío, o bien si hay humedad pero sin calor, o si hace calor pero hay viento...



Implementando un perceptrón

Esta es la información reunida de su comportamiento de los últimos días sábado. Ahora el desafío es construir un perceptrón que aprenda y logre emular las decisiones.

tiempo	temperatura	humedad	viento	Juega Tenis
Soleado	Calor	Alta	Debil	No
Soleado	Calor	Alta	Fuerte	No
Nublado	Calor	Alta	Debil	Si
Lluvia	Agradable	Alta	Debil	Si
Lluvia	Frio	Normal	Debil	Si
Lluvia	Frio	Normal	Fuerte	No
Nublado	Frio	Normal	Fuerte	Si
Soleado	Agradable	Alta	Debil	No
Soleado	Frio	Normal	Debil	Si
Lluvia	Agradable	Normal	Debil	Si
Soleado	Agradable	Normal	Fuerte	Si
Nublado	Agradable	Alta	Fuerte	Si
Nublado	Calor	Normal	Debil	Si
Lluvia	Agradable	Alta	Fuerte	No

Implementando un perceptrón


El siguiente es un perceptrón con 4 entradas y una salida. En donde:

x_1 : tiempo [soleado, nublado, lluvia]

x_2 : temperatura [calor, agradable, frio]

x_3 : humedad [alta, normal]

x_4 : viento [débil, fuerte]

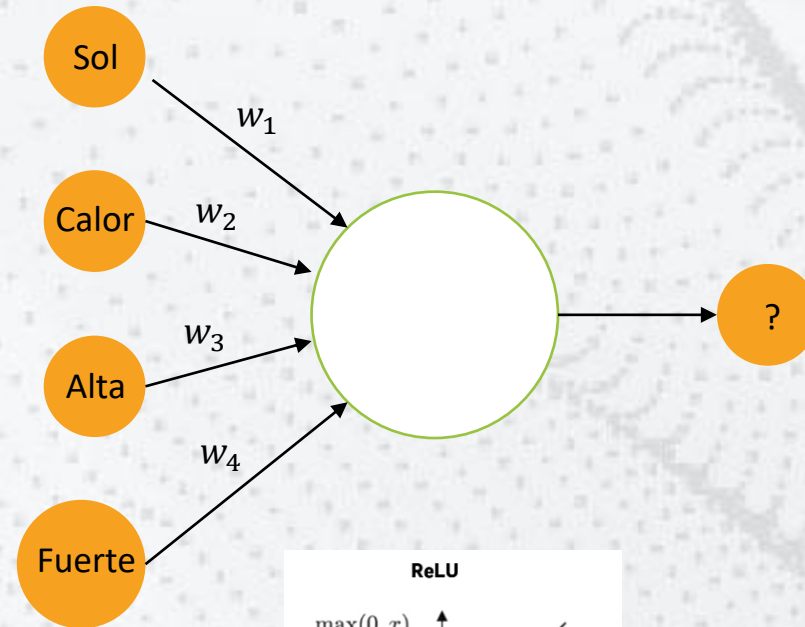


Implementando un perceptrón

Entonces, haremos lo siguiente:

1. Fijaremos valores arbitrarios de w .
2. Ingresaremos cada uno de los datos N registros al perceptrón y calcularemos la salida en cada caso (epoch).
3. Compararemos las salidas del perceptrón con el valor real de cada registro para determinar una métrica de error.
4. Ajustaremos los valores de w y volvemos al punto 2 para repetir el proceso.
5. Cuando hayamos completado una cantidad definida de epochs nos detenemos.

tiempo	temperatura	humedad	viento	Juega Tenis
Soleado	Calor	Alta	Debil	No
Soleado	Calor	Alta	Fuerte	No
Nublado	Calor	Alta	Debil	Si
Lluvia	Agradable	Alta	Debil	Si
Lluvia	Frio	Normal	Debil	Si
Lluvia	Frio	Normal	Fuerte	No
Nublado	Frio	Normal	Fuerte	Si
Soleado	Agradable	Alta	Debil	No
Soleado	Frio	Normal	Debil	Si
Lluvia	Agradable	Normal	Debil	Si
Soleado	Agradable	Normal	Fuerte	Si
Nublado	Agradable	Alta	Fuerte	Si
Nublado	Calor	Normal	Debil	Si
Lluvia	Agradable	Alta	Fuerte	No



Juega Tenis
No
No
Si
Si
Si
No
Si
No
Si
Si
Si
Si
Si
No


Implementando un perceptrón

Sin embargo, debemos codificar las variables categóricas. Así que haremos la siguiente modificación:

Tiempo Soleado	Tiempo Nublado	Temperatura Calor	Temperatura Frio	Humedad Alta	Viento Debil	Juega Tenis
1	0	1	0	1	1	0
1	0	1	0	1	0	0
0	1	1	0	1	1	1
0	0	0	0	1	1	1
0	0	0	1	0	1	1
0	0	0	1	0	0	0
0	1	0	1	0	0	1
1	0	0	0	1	1	0
1	0	0	1	0	1	1
0	0	0	0	0	1	1
1	0	0	0	0	0	1
0	1	0	0	1	0	1
0	1	1	0	0	1	1
0	0	0	0	1	0	0

Implementando un perceptrón

Entonces, nuestro perceptrón tendría 6 nodos de entrada y 1 salida.



Implementando un perceptrón

Definimos algunas funciones convenientes que utilizaremos más adelante.

```
# Define una función que calcule el producto punto entre dos vectores:  
def dot_product(x, w):  
    return np.dot(x, w)
```

Python

```
# Define la función de activación.  
def activation(x):  
    # En este caso, utilizaremos la función escalón (step function):  
    return 1 if x >= 0 else 0
```

Python

Implementando un perceptrón

Esta función es la que realizará el entrenamiento.

```
# Define la función de entrenamiento del perceptrón:
def perceptron_train(X, y, num_epochs, learning_rate):

    # Inicializa los pesos aleatoriamente
    weights = np.random.rand(X.shape[1])

    errors = []

    # iterar las epocas
    for epoch in range(num_epochs):

        epoch_error = 0

        # Itera sobre todos los ejemplos de entrenamiento
        for i in range(X.shape[0]):

            # Calcula la salida del perceptrón
            output = activation(dot_product(X[i], weights))

            # Actualiza los pesos si la salida es incorrecta
            if output != y[i]:
                error = y[i] - output
                weights += learning_rate * error * X[i]
                epoch_error += abs(error)

        errors.append(epoch_error)

    return weights, errors
```


Implementando un perceptrón

Ejecutamos el entrenamiento y obtenemos los pesos w .

```
# Ahora puedes utilizar la función perceptron_train para entrenar el perceptrón con tus datos de entrenamiento:  
# En este ejemplo, utilizamos los datos de entrenamiento X y y para entrenar el perceptrón durante 100 épocas,  
# con una tasa de aprendizaje de 0.1. La función devuelve los pesos entrenados.  
weights, errors = perceptron_train(X, y, num_epochs=30, learning_rate=0.1)
```

Python Python

```
# estos son los pesos calculados  
weights
```

Python Python

```
array([ 0.05290118,  0.94498236,  0.1164077 , -0.05911127, -0.44112394,  
        0.26115013])
```

Implementando un perceptrón

Ahora probamos los pesos del modelo para hacer una predicción sobre un ejemplo.

```
# Para hacer predicciones con el perceptrón entrenado, utiliza la siguiente función:  
def perceptron_predict(x, weights):  
    return activation(dot_product(x, weights))
```

Python Python

```
# Puedes utilizarla para predecir la salida de un ejemplo dado:  
x = np.array([0, 1, 0, 0, 1, 0])  
prediction = perceptron_predict(x, weights)  
print(prediction)
```

Python

Implementando un perceptrón

Evaluamos el desempeño:

```
# hacemos predicciones sobre el set X, por simplicidad no haremos cross validation,  
# pero deberiamos siempre  
y_pred = [perceptron_predict(x, weights) for x in X]  
y_pred
```

Python

```
[0, 0, 1, 0, 1, 0, 1, 0, 1, 1, 1, 1, 1, 0]
```

```
sum(y_pred == y)/len(y)
```

Python

```
0.9285714285714286
```


Implementando un perceptrón

Graficamos el error por epoch.
Nótese cómo después de algunos epochs el error disminuye y se estabiliza en un valor fijo.

```
plt.plot(errors)
```

Python

```
[<matplotlib.lines.Line2D at 0x23b6d11b100>]
```



The background of the slide is a grayscale image of a book cover. The cover features a repeating pattern of stylized, overlapping leaf or feather shapes. A solid green horizontal banner is positioned across the middle of the image, containing the text 'Dudas y consultas' in white.

Dudas y consultas

Gracias